1 Dataset

(Seção de dataset do relatório, não incluída neste PDF; as referências a ela apontam para este marcador.)

2 Resultados

2.1 Configuração experimental

Os fluxos foram extraídos dos PCAPs de terça a sexta-feira da CICIDS2017 com o NFStream e rotulados por IP e horário (Seção 1). Foram usadas 14 variáveis numéricas por fluxo (12 do NFStream mais duas derivadas); IPs, *timestamps*, MACs e identificadores ficaram de fora porque o rótulo foi construído a partir deles. Dos benignos (1.171.671), sortearam-se 300 mil para treino, 100 mil para validação e 100 mil para teste, sem sobreposição. Os ataques com mais de 500 observações (12 classes) foram divididos de forma estratificada em 70%/20%/10%. Sql Injection (9 fluxos) e Heartbleed (1 fluxo) foram descartados. Os modelos foram treinados apenas no conjunto de treino; validação e teste só serviram para calcular métricas.

Foram comparados cinco algoritmos: Regressão Logística, Árvore de Decisão, Random Forest, LightGBM e MLP. As métricas são AUC (ROC), AUC-PR, F1, precisão e revocação; no caso multiclasse, usa-se a média macro entre classes. Como a classe Infiltration tem 55.134 fluxos na rotulagem aqui adotada contra 36 no CSV oficial, todos os experimentos foram executados duas vezes: com e sem essa classe.

2.2 Tarefa 1: classificação binária (benigno × ataque)

Tabela 1: Classificação binária, conjunto de teste, **com** Infiltration.

Modelo	AUC	AUC-PR	F1	Precisão	Revocação
Regressão Logística	0,9823	0,9355	0,8782	0,8102	0,9588
Árvore de Decisão	0,9978	0,9904	0,9764	0,9550	0,9988
Random Forest	0,9974	0,9849	0,9838	0,9690	0,9989
LightGBM	0,9990	0,9962	0,9812	0,9641	0,9989
MLP	0,9987	0,9948	0,9792	0,9656	0,9933

Tabela 2: Classificação binária, conjunto de teste, **sem** Infiltration.

Modelo	AUC	AUC-PR	F1	Precisão	Revocação
Regressão Logística	0,9886	0,9355	0,8862	0,8221	0,9612
Árvore de Decisão	0,9986	0,9934	0,9867	0,9751	0,9986
Random Forest	0,9993	0,9948	0,9960	0,9931	0,9990
LightGBM	0,9997	0,9987	0,9933	0,9882	0,9985
MLP	0,9996	0,9981	0,9913	0,9903	0,9924

Os quatro modelos não lineares ficam muito próximos (AUC-PR entre 0,985 e 0,999), e a Regressão Logística é claramente inferior (0,936). O LightGBM tem o maior AUC-PR

nas duas execuções, e o Random Forest o maior F1. Como há uma única semente e um único *split*, as diferenças entre os quatro primeiros não permitem apontar um vencedor. Retirar a Infiltration melhorou quase todas as métricas, principalmente a precisão (por exemplo, Random Forest de 0,969 para 0,993), o que sugere que parte dos falsos positivos vinha dessa classe.

2.3 Tarefa 2: classificação multiclasse

Tabela 3: Classificação multiclasse (média macro), conjunto de teste, **com** Infiltration.

Modelo	AUC	AUC-PR	F1	Precisão	Revocação
Regressão Logística	0,9940	0,6376	0,6089	0,5293	0,9032
Árvore de Decisão	0,9868	0,8766	0,8929	0,8858	0,9404
Random Forest	0,9791	0,8911	0,9110	0,8935	0,9332
LightGBM	0,9995	0,8791	0,8868	0,8618	0,9433
MLP	0,9992	0,8653	0,8429	0,9591	0,8499

Tabela 4: Classificação multiclasse (média macro), conjunto de teste, **sem** Infiltration. †: falha de treinamento do LightGBM nesta execução; resultado descartado.

Modelo	AUC	AUC-PR	F1	Precisão	Revocação
Regressão Logística	0,9941	0,5920	0,5705	0,4884	0,8996
Árvore de Decisão	0,9841	0,8682	0,8866	0,8711	0,9357
Random Forest	0,9745	0,8902	0,9092	0,8920	0,9304
LightGBM†	0,5683	0,1533	0,1623	0,2273	0,1844
MLP	0,9995	0,8587	0,8313	0,9633	0,8371

A tarefa multiclasse é mais difícil: o melhor AUC-PR macro é 0,891 (Random Forest), contra 0,996 no caso binário. O Random Forest teve o melhor AUC-PR e o melhor F1 nas duas execuções. A AUC macro é enganosa aqui: a Regressão Logística tem AUC 0,994 com F1 de apenas 0,609, porque a AUC é inflada pelo enorme número de negativos em classes raras. Por isso a comparação se apoia em AUC-PR e F1.

A Tabela 6 mostra de onde vem a queda. Com o Random Forest, a maioria das classes tem AUC-PR acima de 0,89, e a perda se concentra em *Web Attack – Brute Force* (0,578) e *Web Attack – XSS* (0,258). Essas duas classes têm poucos exemplos (135 e 66 no teste) e provavelmente se confundem entre si, já que ambas são tráfego HTTP contra o mesmo servidor; esta última hipótese ainda não foi verificada com matriz de confusão. O desempenho de treino nessas classes é muito maior (AUC-PR de 0,973 e 0,969), o que indica sobreajuste. O MLP quase não prevê essas classes (revocação de 0,074 e 0,045 no teste, com precisão acima de 0,90), e é isso que produz sua precisão macro alta (0,959) com revocação baixa. Vale registrar que, diferentemente dos demais, o MLP não usou ponderação de classes.

2.4 Tarefa 3: um classificador binário por ataque

Foi usado o Random Forest, melhor modelo pela média do AUC-PR entre as tarefas 1 e 2 (0,9380 contra 0,9377 do LightGBM, um empate prático). Para cada ataque, treinou-se

um modelo com os benignos e apenas aquele ataque.

Tabela 5: Random Forest, um ataque contra benignos, conjunto de teste, **com** Infiltration.

Ataque	n	AUC	AUC-PR	F1	Precisão	Revocação
PortScan	16014	0,9995	0,9941	0,9973	0,9947	0,9999
DDoS	6298	0,9999	0,9975	0,9967	0,9934	1,0000
Infiltration	5513	0,9965	0,8911	0,9280	0,8665	0,9987
DoS Hulk	1429	1,0000	1,0000	0,9993	1,0000	0,9986
DoS GoldenEye	766	1,0000	0,9986	0,9967	0,9948	0,9987
DoS slowloris	448	1,0000	0,9973	0,9933	0,9889	0,9978
DoS Slowhttptest	437	1,0000	0,9905	0,9954	0,9909	1,0000
FTP-Patator	395	1,0000	0,9949	0,9962	0,9925	1,0000
SSH-Patator	246	0,9998	0,8851	0,9245	0,8627	0,9959
Web Attack – Brute Force	135	0,9888	0,9583	0,9314	0,9085	0,9556
Bot	73	1,0000	1,0000	1,0000	1,0000	1,0000
Web Attack – XSS	66	0,9922	0,9074	0,8657	0,8529	0,8788

Os resultados sem Infiltration são praticamente os mesmos nas demais classes (por exemplo, SSH-Patator com AUC-PR 0,8935 contra 0,8851). As classes mais difíceis são Infiltration, SSH-Patator e as duas Web Attack, todas com a precisão mais baixa e a revocação alta. Bot tem desempenho perfeito, mas com apenas 73 exemplos no teste, o que limita a confiança nesse número.

Tabela 6: AUC-PR por classe no conjunto de teste, com Infiltration: Random Forest multiclasse contra Random Forest binário por ataque.

Classe	Multiclasse	Por ataque
PortScan	0,9941	0,9941
DDoS	0,9972	0,9975
Infiltration	0,8902	0,8911
DoS Hulk	0,9993	1,0000
DoS GoldenEye	0,9972	0,9986
DoS slowloris	0,9986	0,9973
DoS Slowhttptest	0,9915	0,9905
FTP-Patator	0,9949	0,9949
SSH-Patator	0,8869	0,8851
Web Attack – Brute Force	0,5784	0,9583
Bot	0,9993	1,0000
Web Attack – XSS	0,2581	0,9074

2.5 Discussão

Qual tipo de modelo é melhor? Depende da pergunta que se quer responder, e as três abordagens não são diretamente comparáveis, pois cada uma é avaliada em um conjunto de classes diferente. Para detectar se há ataque, o modelo binário é o mais simples e atinge AUC-PR de até 0,999. Para identificar *qual* ataque, o multiclasse entrega o diagnóstico

completo com um único modelo, e perde desempenho apenas nas classes mais raras e parecidas entre si. A Tabela 6 mostra que, para 10 das 12 classes, o modelo multiclasse e os modelos por ataque têm AUC-PR praticamente idênticos. Os modelos por ataque só ganham nas duas Web Attack (0,958 contra 0,578 e 0,907 contra 0,258), ao custo de 12 modelos e de saber de antemão qual aplicar.

Qual a melhor técnica? Os métodos baseados em árvores foram os mais consistentes: Random Forest e LightGBM ficaram no topo em todas as tarefas, com Random Forest à frente no multiclasse e LightGBM à frente no binário, e a diferença média entre eles é desprezível. A Árvore de Decisão chega perto com tempo de treino muito menor (4 a 5 s contra 31 a 38 s do Random Forest no caso binário). O MLP é competitivo no binário, mas tem dificuldade com classes raras. A Regressão Logística é a pior em todos os cenários, o que indica que a fronteira entre as classes não é linear nessas variáveis.

Limitações. (i) Foi usada uma única semente e um único *split*, sem intervalos de confiança; as diferenças pequenas entre modelos não são conclusivas. (ii) O LightGBM multiclasse falhou na execução sem Infiltration e esse resultado foi descartado. (iii) O MLP não usou ponderação de classes, ao contrário dos demais. (iv) O rótulo vem de IP e horário (Seção 1); a classe Infiltration é muito maior do que no CSV oficial e parece se confundir com tráfego benigno. (v) As classes Bot e Web Attack têm poucos exemplos no teste (73, 135 e 66), então suas métricas variam bastante. (vi) Métricas calculadas com limiar 0,5, sem ajuste na validação.